

---

# Identificação de Sistemas Dinâmicos

Péricles Rezende Barros

---

## Introdução

### Definição do problema

Obter um modelo dentre uma classe de modelos com uma estrutura particular que descreva comportamento do sistema usando dados reais de operação.

### Etapas na identificação de sistemas dinâmicos

- Planejamento do experimento
  - Como obter dados frente a restrições econômicas, físicas, operacionais e de segurança
- Estruturas para o modelo
  - Construção de classe de modelo usando conhecimento a-priori
- Estimação de Parâmetros
  - Definição do critério, e determinação do modelo (ordem e parâmetros) usando dados reais
- Validação
  - Usar dados adicionais para verificar como o modelo representa o sistema para outras entradas

# Modelos de Processos

## Classe de Modelos Contínuos no Tempo

Considere o modelo de primeira ordem, contínuo no tempo

$$G(s) = \frac{b}{s+a} e^{-Ls} \quad (1)$$

o qual supõe-se representa o comportamento dinâmico do processo. Os dados de entrada e saída estão disponíveis de forma amostrada. Assume-se que o processo está em regime estacionário no tempo  $t = 0$  de modo que  $u(t) = 0$  para  $t < 0$  e que o sistema tem condições iniciais nulas. Para  $t \geq L$  o processo satisfaz a equação diferencial

$$\dot{y}(t) + ay(t) = bu(t - L). \quad (2)$$

Integrando a Eq.(2) de  $\tau = 0$  de  $\tau = t$

$$y(t) = -a \int_0^t y(\tau) d\tau + b \int_0^t u(\tau - L) d\tau. \quad (3)$$

Assumindo uma entrada degrau com amplitude  $A$  aplicada em  $t = 0$  pode-se também escrever

$$y(t) = -a \int_0^t y(\tau) d\tau + bAt - bAL, \quad (4)$$

para a qual se pode construir o modelo em regressão com

$$\begin{aligned} \phi(t) &= \left[ -\int_0^t y(\tau) d\tau \quad At \quad -A \right]^T, \\ \theta &= \left[ a \quad b \quad bL \right]^T. \end{aligned} \quad (5)$$

e a Eq.(??) pode ser escrita em forma de regressão linear

$$y(t) = \phi(t)^T \theta.$$

A integral pode ser calculada usando-se um método de integração (Tustin/bilinear).

### Classe de Modelos Discretos no Tempo

Considere o sistema discreto no tempo na representação entrada-saída no operador  $q$

$$y(t) = G(q)u(t). \quad (6)$$

$$G(q) = \frac{B(q)}{A(q)} \quad (7)$$

---

com

$$A(q) = 1 + a_{n-1}q^{-1} + \dots + a_0q^{-n} \quad (8)$$

$$B(q) = b_mq^{m-n} + \dots + b_0q^{-n} \quad (9)$$

então o sistema pode ser reescrito como

$$A(q)y(t) = B(q)u(t)$$

$$y(t) + a_{n-1}y(t-1) + \dots + a_0y(t-n) = b_mu(t-d) + \dots + b_0u(t-n). \quad (10)$$

$$y(t) = B(q)u(t) + [1 - A(q)]y(t). \quad (11)$$

O modelo definido pela equação é conhecido como ARX, onde AR se refere à parte autoregressiva  $A(q)y(t)$ , e X à entrada externa  $B(q)u(t)$ .

Definindo-se o vetor de parâmetros  $\theta$  como,

$$\theta^T = [a_{n-1} \quad \dots \quad a_0 \quad b_m \quad \dots \quad b_0]$$

então a classe de modelos definida por

$$\hat{y}(t|\theta) = G(q, \theta)u(t) \quad (12)$$

$$A(q, \theta)y(t) = B(q, \theta)u(t) \quad (13)$$

---

com  $G(q, \theta)$  dado por

$$G(q, \theta) = \frac{B(q, \theta)}{A(q, \theta)}$$

é dependente de  $\theta$  e o modelo a ser determinado para representar o sistema corresponde a um valor particular para  $\theta$

O desenvolvimento acima pode ser repetido para modelos no operador  $\delta$  resultando em

$$\hat{y}(t|\theta) = G(\delta, \theta) u(t) \quad (14)$$

com  $G(\delta, \theta)$  dado por

$$G(\delta, \theta) = \frac{B(\delta, \theta)}{A(\delta, \theta)}$$

---

Pode-se escrever a saída do modelo na forma de uma regressão

$$\hat{y}(t|\theta) = B(q, \theta) u(t) + [1 - A(q, \theta)] y(t). \quad (15)$$

ou

$$\hat{y}(t|\theta) = \phi^T(t) \theta. \quad (16)$$

onde

$$\begin{aligned} \phi(t)^T &= \begin{bmatrix} -y(t-1) & -y(t-2) & \cdots & -y(t-n) & u(t-n+m) & \cdots & u(t-m) \end{bmatrix} \\ \theta^T &= \begin{bmatrix} a_{n-1} & \cdots & a_0 & b_m & \cdots & b_0 \end{bmatrix} \end{aligned} \quad (17)$$

Erro de predição

Saída real menos a saída do modelo

$$\varepsilon(t, \theta) = y(t) - \hat{y}(t|\theta) \quad (18)$$

$$= y(t) - \phi^T(t) \theta. \quad (19)$$

$$A(\delta)y(t) = B(\delta)u(t)$$

Filtrando os sinais pelo polinômio mônico estável  $E(\delta)$  resulta na equação

$$A(\delta) \left( \frac{y(t)}{E(\delta)} \right) = B(\delta) \left( \frac{u(t)}{E(\delta)} \right)$$

ou, na forma de regressão linear

$$y(t) = \phi^T(t)\theta$$

$$\phi^T(t) = [\delta^{n-1}y_f(t) \ \delta^{n-2}y_f(t) \ \cdots \ y_f(t) \ \delta^m u_f(t) \ \cdots \ u_f(t)]$$

$$\theta = [(e_{n-1} - a_{n-1}) \ (e_{n-2} - a_{n-2}) \ \cdots \ (e_0 - a_0) \ b_m \ \cdots \ b_0]$$

$$y_f(t) = \frac{y(t)}{E(\delta)} \quad \text{e} \quad u_f(t) = \frac{u(t)}{E(\delta)}.$$



Assuma que foram realizadas medições da entrada  $u(t)$  e da saída  $y(t)$  durante  $N$  períodos de amostragem. Defina a matriz de dados

$$Z(N) = \begin{bmatrix} y(1) & y(2) & \cdots & y(N-1) & y(N) \\ u(1) & u(2) & \cdots & u(N-1) & u(N) \end{bmatrix}^T.$$

O objetivo da estimação de parâmetros é obter um vetor  $\theta$  tal que o erro  $\varepsilon(\cdot, \theta)$  seja pequeno de acordo com uma certa função de custo (ou critério de desempenho).

Defina a função de custo mínimos quadrados

$$V_N(\theta, Z(N)) = \frac{1}{N} \sum_{t=1}^N [y(t) - \phi^T(t) \theta]^2. \quad (20)$$

A estimativa para os parâmetros mínimos quadrados  $\hat{\theta}^{LS}(N)$  é obtida de

$$\hat{\theta}^{LS}(N) = \arg \min_{\theta} V_N(\theta, Z(N)). \quad (21)$$

Como  $V_N$  é quadrática em  $\theta$ , pode-se encontrar o valor mínimo derivando a equação acima. Assim,

$$\frac{d}{d\theta} V_N(\theta, Z(N)) = \frac{2}{N} \sum_{t=1}^N \phi(t) (y(t) - \phi^T(t) \theta),$$

---

e

$$\frac{2}{N} \sum_{t=1}^N \phi(t) y(t) = \frac{2}{N} \sum_{t=1}^N \phi(t) \phi^T(t) \theta.$$

A estimativa pode ser calculada como

$$\hat{\theta}(N) = \hat{\theta}^{LS}(N) = \left[ \sum_{t=1}^N \phi(t) \phi^T(t) \right]^{-1} \sum_{t=1}^N \phi(t) y(t)$$

onde assume-se que a inversa existe.

## Mínimos Quadrados Recursivo

Se após calcular  $\hat{\theta}(t-1)$  novos dados,  $y(t)$  e  $u(t)$  se tornaram disponíveis, para se calcular  $\hat{\theta}(t)$  é necessário recalcular a inversa da matriz na equação acima. No entanto, é possível reescrever a equação do mínimos quadrados de forma recursiva. Defina

$$\hat{\theta}^{LS}(N) = R^{-1}(N) f(N),$$

$$R(t) = \sum_{k=1}^t \phi(k) \phi^T(k)$$

$$f(t) = \sum_{k=1}^t \phi(k) y(k).$$

$$R(t) = R(t-1) + \phi(t) \phi^T(t),$$

$$f(t) = f(t-1) + \phi(t) y(t),$$

$$\begin{aligned}
\widehat{\theta}(t) &= R^{-1}(t) f(t) \\
&= R^{-1}(t) [f(t-1) + \phi(t) y(t)] \\
&= R^{-1}(t) f(t-1) + R^{-1}(t) \phi(t) y(t) \\
&= R^{-1}(t-1) f(t-1) + [R^{-1}(t) - R^{-1}(t-1)] f(t-1) + R^{-1}(t) \phi(t) y(t) \\
&= \widehat{\theta}(t-1) + R^{-1}(t) \phi(t) y(t) + [R^{-1}(t) - R^{-1}(t-1)] f(t-1).
\end{aligned}$$

Mas

$$\begin{aligned}
R(t) - R(t-1) &= \phi(t) \phi^T(t) \\
R(t) [I - R^{-1}(t) R(t-1)] &= \phi(t) \phi^T(t) \\
[I - R^{-1}(t) R(t-1)] &= R^{-1}(t) \phi(t) \phi^T(t),
\end{aligned}$$

$$\begin{aligned}
[R^{-1}(t) - R^{-1}(t-1)] f(t-1) &= [R^{-1}(t) R(t-1) - I] R^{-1}(t-1) f(t-1) \\
&= -R^{-1}(t) \phi(t) \phi^T(t) R^{-1}(t-1) f(t-1) \\
&= -R^{-1}(t) \phi(t) \phi^T(t) \widehat{\theta}(t-1)
\end{aligned}$$

$$\widehat{\theta}(t) = \widehat{\theta}(t-1) + R^{-1}(t) \phi(t) \left[ y(t) - \phi^T(t) \widehat{\theta}(t-1) \right].$$

---

Agora o estimador é recursivo pois pode ser calculado a partir dos valores calculados no instante anterior e das novas medições.

Também é possível evitar a inversão matricial de  $R(t)$  a cada passo. Defina

$$P(t) = R^{-1}(t).$$

Aplique o lema da inversão matricial,

$$[A + BCD]^{-1} = A^{-1} - A^{-1}B[DA^{-1}B + C^{-1}]^{-1}DA^{-1},$$

com  $A = R(t-1)$ ,  $B = D^T = \phi(t)$  e  $C = 1$ ,

$$P(t) = \left[ P(t-1) - \frac{P(t-1)\phi(t)\phi^T(t)P(t-1)}{1 + \phi^T(t)P(t-1)\phi(t)} \right] \frac{1}{\lambda(t)} \quad (22)$$

e

$$R^{-1}(t)\varphi(t) = \frac{P(t-1)\phi(t)}{1 + \phi^T(t)P(t-1)\phi(t)}.$$

Resumindo, o algoritmo recursivo é dado por,

---

$$\hat{\boldsymbol{\theta}}(t) = \hat{\boldsymbol{\theta}}(t-1) + L(t) \left[ y(t) - \boldsymbol{\phi}^T(t) \hat{\boldsymbol{\theta}}(t-1) \right], \quad (23)$$

$$L(t) = \frac{P(t-1) \boldsymbol{\phi}(t)}{1 + \boldsymbol{\phi}^T(t) P(t-1) \boldsymbol{\phi}(t)},$$

$$P(t) = \left[ P(t-1) - \frac{P(t-1) \boldsymbol{\phi}(t) \boldsymbol{\phi}^T(t) P(t-1)}{1 + \boldsymbol{\phi}^T(t) P(t-1) \boldsymbol{\phi}(t)} \right].$$

## Parâmetros Variantes no Tempo

Para parâmetros variantes no tempo, definindo a função de custo ponderada exponencialmente

$$V(\theta, t) = \frac{1}{2} \sum_{i=1}^t \lambda^{t-i} (y(i) - \phi^T(i)\theta)^2$$

resulta no algoritmo Mínimos Quadrados Recursivos com Esquecimento Exponencial

$$\hat{\theta}(t) = \hat{\theta}(t-1) + K(t)(y(t) - \phi^T(t)\hat{\theta}(t-1))$$

$$K(t) = P(t)\phi(t) = P(t-1)\phi(t)(\lambda I + \phi^T(t)P(t-1)\phi(t))^{-1}$$

$$\begin{aligned} P(t) &= P(t-1) - P(t-1)\phi(t)(\lambda I + \phi^T(t)P(t-1)\phi(t))^{-1} \\ &= (I - K(t)\phi^T(t))P(t-1)/\lambda \end{aligned}$$

# Estimação Robusta de Parâmetros

Controle adaptativo  $\times$  Ruído e dinâmicas não modeladas

- Filtragem passa-faixa
- Normalização
- Variação de parâmetros

$$P(t) = (I - K(t)\phi^T(t))P(t-1)/\lambda$$

$$\phi^T(t) = 0 \quad P(t) \nearrow$$

- Zona morta